

Slides DeclarAI Agentic RAG

Prompt para NotebookLM - Slides DeclarAI: Agentic RAG

Use este conteúdo como prompt para gerar uma apresentação profissional sobre o DeclarAI. A apresentação deve priorizar as melhorias implementadas desde a versão anterior do projeto, destacando a evolução da versão atual.

Este PDF deve ser usado como briefing único para o NotebookLM. Ele contém contexto, problema, solução, roteiro de slides, padrão visual, diagramas existentes e regras de composição. Gere uma apresentação 16:9, profissional, clara, em português brasileiro e pronta para demonstração acadêmica.

Objetivo do Slide Deck

Criar uma apresentação sobre o DeclarAI, um Micro SaaS acadêmico com Agentic RAG para apoiar a organização de documentos e dúvidas sobre a declaração do Imposto de Renda Pessoa Física no Brasil.

A apresentação deve convencer a banca de que o projeto atende aos requisitos da atividade, com foco em:

- problema real e domínio claramente delimitado;
- base de conhecimento própria;
- pipeline RAG com ingestão, chunking, embeddings, recuperação e re-ranking;
- comportamento Agentic RAG com ferramentas;
- LLM aberto via Ollama;
- interface web utilizável;
- avaliação quantitativa com dataset anotado;
- documentação, diagramas e demonstração ao vivo.

Regras de Geração da Apresentação

- Gerar exatamente 18 slides.
- Usar formato widescreen 16:9.
- Usar português brasileiro com acentuação correta.
- Não criar informações, métricas, autores, endpoints ou tecnologias que não estejam neste PDF.
- Não usar conteúdo genérico de imposto de renda fora do contexto do projeto.

- Não transformar o DeclarAI em produto comercial real. Tratar como Micro SaaS acadêmico.
- Não dizer que o sistema substitui contador. Sempre posicionar como apoio informativo.
- Evitar blocos longos de texto. Preferir frases curtas, tabelas pequenas, diagramas e bullets objetivos.
- Cada slide deve ter título forte, mensagem principal e visual associado quando houver diagrama indicado.
- Não usar travessão. Use hífen simples quando precisar separar ideias.

Direção Visual

- Todos os slides devem ter fundo off-white, preferencialmente #FAF9F6.
- Usar laranja #F97316 para títulos, destaques e ícones principais.
- Usar amarelo dourado #FBBF24 para badges, chamadas e divisores.
- Usar preto suave #1A1A1A e grafite #172033 para textos.
- Usar verde-teal #0F766E apenas como cor de apoio para métricas e barras.
- Evitar fundo escuro, gradientes pesados, blocos poluídos e setas sobrepostas.
- Preferir diagramas simples, com muito respiro, cartões claros e tipografia sem serifa.
- Usar cartões apenas para informações comparáveis, métricas, etapas e componentes.
- Manter margens generosas e alinhamento consistente.
- Usar no máximo 5 bullets por slide.
- Quando houver diagrama, ele deve ser o elemento visual principal.
- Não colocar texto sobre diagramas de forma que prejudique leitura.

Padrão de Títulos, Rodapé e Layout

- Título de slide: topo esquerdo, cor #F97316, peso alto, fonte de **50px**.
- Subtítulo ou frase guia: abaixo do título, cor #172033, fonte de 27px.
- Corpo de texto, tabelas e bullets: fonte de 27px.
- Notas, observações, alertas e textos secundários: fonte de 23px.
- Rodapé em todos os slides, exceto se a capa ficar visualmente melhor sem rodapé.
- Rodapé sugerido: DeclarAI | UEA | Oficina e Desenvolvimento de Sistemas I | Junho de 2026.
- Numeração discreta no canto inferior direito, formato 01/18, 02/18 e assim por diante.
- Usar logotipo pequeno do DeclarAI no rodapé ou no canto superior direito.
- Capa: criar composição nova, limpa e institucional. Não usar diagrams/cover_slide.svg como layout principal.
- Capa deve usar o nome DeclarAI como elemento mais forte da primeira tela.
- A capa deve mostrar equipe, disciplina, instituição e data sem parecer pôster poluído.

Banco Visual Disponível

Use os arquivos abaixo como referência visual. Ao montar os slides, incorpore os diagramas indicados nas seções de cada slide.

Arquivo	Uso recomendado
diagrams/logo.svg	marca horizontal do DeclarAI
diagrams/logo_icon.svg	ícone pequeno para rodapé, capa ou detalhes
diagrams/agentik_rag/c4_contexto.svg	arquitetura em nível de contexto
diagrams/agentik_rag/c4_containers.svg	arquitetura de contêineres
diagrams/agentik_rag/fluxo_agentico.svg	decisão do agente por tipo de entrada
diagrams/agentik_rag/ferramentas_agente.svg	ferramentas do agente
diagrams/agentik_rag/recuperacao_reranking.svg	recuperação e re-ranking
diagrams/agentik_rag/classificacao_llm_first.svg	classificação LLM-first
diagrams/agentik_rag/titularidade_justificativa.svg	titularidade e justificativa
diagrams/agentik_rag/pipeline_rag.svg	pipeline RAG completo
diagrams/agentik_rag/indexacao_e_ingestao.svg	ingestão e pré-processamento
diagrams/chunking_estrategia.svg	estratégia de chunking
diagrams/agentik_rag/avaliacao_rag.svg	métricas de avaliação
diagrams/cover_slide.svg	capa antiga, usar apenas como referência de paleta se necessário

Contexto do Projeto

Título geral: DeclarAI: Agentik RAG para apoio à declaração do IRPF

Instituição: Universidade do Estado do Amazonas

Disciplina: Oficina e Desenvolvimento de Sistemas I

Equipe: Juliana Ballin Lima, 2315310011, e Fernando Luiz Da Silva Freire, 2315310007

Data: Junho de 2026

Repositório: apresentar a versão atual do projeto.

Contexto Técnico Sintético

O DeclarAI possui backend FastAPI, frontend React + Vite, banco SQLite para histórico, ChromaDB para vetores, embeddings com sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2, re-ranking com cross-encoder/mmarco-mMiniLMv2-L12-H384-v1 e LLM aberto mistral executado via Ollama.

O fluxo principal é:

Usuário

- |
- + Frontend React
- |
- + API FastAPI
- |
- + Ferramentas do agente
 - + Chat RAG
 - + Upload fiscal
 - + Classificação LLM-first
 - + Verificação de titularidade
 - + Justificativa RAG
 - + Histórico SQLite
 - + Avaliação do pipeline

Problema, Solução e Valor

Problema: contribuintes leigos têm dificuldade para organizar documentos do IRPF, diferenciar despesas dedutíveis de não dedutíveis, separar titular, dependentes e terceiros, e entender regras fiscais com base em documentos confiáveis.

Solução: um assistente local com Agentic RAG que consulta uma base fiscal própria, processa documentos, classifica categorias tributárias, verifica titularidade e gera justificativas fundamentadas.

Valor: reduzir erros de organização, melhorar a revisão documental, preservar privacidade e facilitar a demonstração dos critérios técnicos da atividade.

Slide 1: Capa

Título: DeclarAI

Subtítulo: Agentic RAG para apoio inteligente à declaração do IRPF

Mensagem principal: Micro SaaS acadêmico com LLM aberto, execução local, base de conhecimento fiscal e classificação automática de documentos.

Visual sugerido: fundo off-white, nome DeclarAI grande, logo pequeno, selo IRPF 2026 como detalhe visual, nomes dos integrantes e UEA no rodapé.

Instrução de composição: criar capa nova, sem reaproveitar a capa antiga. A capa deve parecer acadêmica, limpa e moderna, com foco no nome DeclarAI.

Slide 2: Estrutura de Apresentação

Título: Estrutura de Apresentação

Mensagem principal: organizar a banca para entender problema, arquitetura, evolução, avaliação e demonstração.

Tópicos do sumário:

- 1. Problema real e proposta de valor.
- 2. Arquitetura e Agentic RAG.
- 3. Evolução da versão anterior para a versão atual.
- 4. Base de conhecimento, chunking e modelos locais.
- 5. Avaliação quantitativa e resultados.
- 6. Demonstração ao vivo, limitações e próximos passos.

Visual sugerido: sumário em duas colunas, com ícones simples e uma linha de progresso discreta.

Slide 3: Problema Real

Título: Por que o DeclarAI é necessário?

A declaração do IRPF exige que contribuintes organizem recibos, notas fiscais, informes e comprovantes ao longo do ano. Usuários que não são contadores costumam ter dificuldades para:

- identificar despesas dedutíveis;
- evitar despesas que a Receita Federal não aceita;
- separar documentos do titular, dependentes e terceiros;
- entender limites, regras e comprovantes necessários.

Proposta de valor: um assistente especializado no domínio fiscal brasileiro, com respostas fundamentadas em documentos de referência e processamento local de dados sensíveis.

Slide 4: Arquitetura Geral

Título: Arquitetura do DeclarAI

Use um diagrama por camadas e destaque a execução local:

Camada	Tecnologia	Papel
Frontend	React + Vite	Chat, upload, base, histórico, avaliação e status
API	FastAPI	Rotas REST, Swagger e orquestração dos serviços
RAG	MiniLM + ChromaDB	Indexação, embeddings e recuperação semântica

Camada	Tecnologia	Papel
Re-ranking	CrossEncoder	Reordenação contextual dos trechos recuperados
LLM	Mistral via Ollama	Geração de respostas, classificação e justificativas
Persistência	SQLite + ChromaDB	Histórico de documentos e vetores

Diferencial: execução local, sem envio de documentos fiscais para APIs externas.

Por que apenas modelos locais (sem APIs de nuvem)?

Documentos fiscais contêm dados altamente sensíveis: CPF, renda anual, informações de saúde, dependentes, valores de patrimônio. O envio desses dados para APIs externas (OpenAI, Gemini, Claude) representaria:

- Risco de violação da LGPD (Lei Geral de Proteção de Dados);
- Dependência de internet e disponibilidade de serviço externo;
- Custo recorrente por token, inviável para projeto acadêmico;
- Perda de controle sobre como os dados são usados e armazenados.

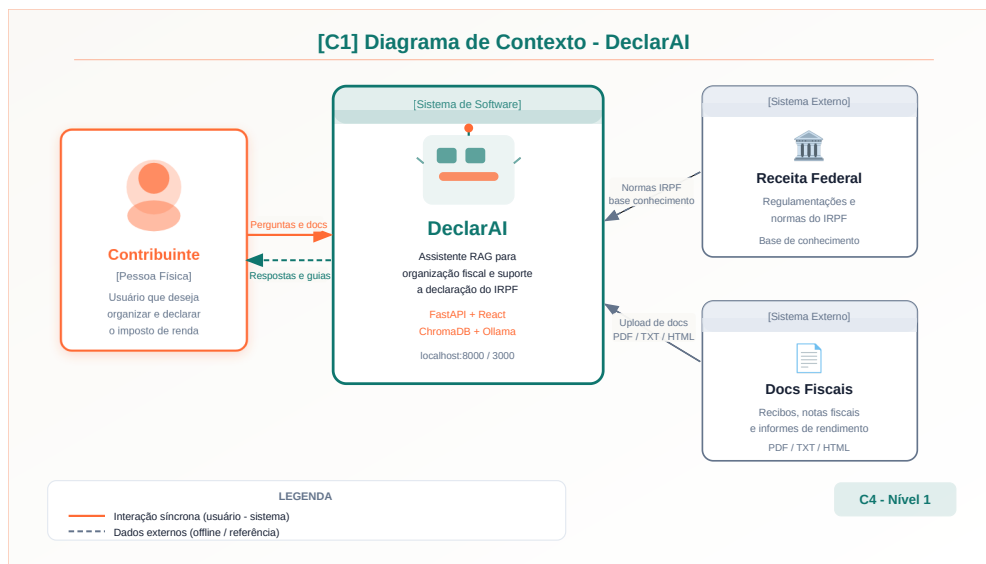
A execução local via Ollama resolve todos esses pontos: os dados nunca saem do ambiente do usuário.

Justificativa de cada modelo escolhido:


Modelo	Papel	Justificativa
Mistral (Ollama)	Geração e classificação	Licença aberta, melhor cobertura no domínio fiscal (72,4%), bom suporte ao PT-BR
MiniLM-L12-v2 (multilingual)	Embeddings	Leve, multilíngue (suporta PT-BR), 384 dimensões, compatível com CPU
CrossEncoder mmarco multilingual	Re-ranking	Re-ranqueamento multilíngue, melhora qualidade em perguntas com negações fiscais

Diagramas disponíveis:

- Contexto geral: `diagrams/agentik_rag/c4_contexto.svg`
- Contêineres: `diagrams/agentik_rag/c4_containers.svg`



Contexto C4



Contêineres C4

Slide 5: Agentic RAG

Título: O agente escolhe a ferramenta certa

Mostrar um diagrama de decisão:

Entrada do usuário

- |
- + Pergunta sobre IRPF -> Chat RAG
- + Documento enviado -> Upload fiscal
- + Consulta de documentos -> Histórico SQLite
- + Avaliação -> Métricas do pipeline


Ferramentas implementadas:

1. Busca vetorial com ChromaDB.
2. Re-ranking com CrossEncoder.


3. Classificação LLM-first com fallback por regras.
4. Verificação de titularidade.
5. Justificativa enriquecida com segundo pipeline RAG.
6. Consulta ao histórico e resumo anual.

Diagramas disponíveis:

- Fluxo de decisão do agente: diagrams/agentic_rag/fluxo_agentico.svg
- Ferramentas do agente: diagrams/agentic_rag/ferramentas_agente.svg



Fluxo Agêntico



Ferramentas do Agente

Slide 6: Evolução 1 - Re-ranking Semântico

Título: Re-ranking semântico com CrossEncoder

Versão anterior: a busca vetorial retornava trechos apenas por similaridade de embedding.

Versão atual: o ChromaDB recupera top-15 candidatos e o CrossEncoder reordena os pares pergunta + trecho, retornando os top-5 mais relevantes.

Impacto técnico:

- melhora perguntas com negações fiscais, como “não é dedutível”;
- reduz contexto irrelevante enviado ao LLM;
- aumenta a confiança das fontes exibidas ao usuário.

Arquivo principal: backend/app/rag/retriever.py

Diagrama: diagrams/agentric_rag/recuperacao_reranking.svg



Recuperação e Re-ranking

Slide 7: Evolução 2 - Classificação LLM-first

Título: Classificação mais flexível de documentos fiscais

Versão anterior: classificação por palavras-chave fixas.

Versão atual: o Mistral tenta classificar primeiro. Se o resultado for inválido ou incerto, o sistema usa fallback por regras.

Fluxo:

Texto extraído

```
|
+ Mistral classifica categoria
|
+ Categoria válida? sim -> origem_classificacao = llm
|
+ Categoria válida? não -> fallback por regras
```

Categorias reconhecidas:

- despesa_medica
- despesa_educacional
- previdencia_privada
- rendimentos
- deducacao_aluguel
- pensao_alimenticia
- doacoes
- outros_ao_dedutivel

Por que usar LLM para classificação?

A classificação por palavras-chave fixas falha em documentos com linguagem informal, abreviações médicas ou termos regionais. O LLM interpreta o contexto completo do documento, reduzindo falsos negativos e permitindo identificar categorias ambíguas. O fallback por regras garante segurança quando o Ollama não está disponível.


Como o Mistral foi selecionado para classificação?

Foram avaliados quatro modelos locais via Ollama no dataset de 60 perguntas do domínio IRPF:

Modelo	Cobertura (%)	Latência (s)
Mistral + RAG	72,4	8,2
Phi-4 Mini + RAG	68,3	7,0
Llama 3.2:3b + RAG	65,8	6,4
Gemma 3:4b + RAG	61,2	6,9

O Mistral foi escolhido por apresentar a maior cobertura de palavras-chave esperadas (72,4%) e bom suporte ao português brasileiro, com custo computacional compatível com CPUs comuns. Os demais modelos foram descartados por cobertura inferior no domínio fiscal.

Diagrama: diagrams/agentico_rag/classificacao_llm_first.svg



Classificação LLM-first

Slide 8: Evolução 3 - Titularidade

Título: Verificação de titular, dependente ou terceiro

Problema resolvido: despesas de terceiros não dependentes não são dedutíveis, mesmo quando foram pagas pelo declarante.


Implementação:

- POST /declarante/perfil registra nome e CPF do declarante.
- POST /declarante/verificar-titularidade compara beneficiário e declarante.
- O frontend agora exibe o resultado na tela de upload.

Estados possíveis:

Resultado	Ação recomendada
Titular	Documento pode seguir para revisão
Dependente provável	Usuário deve confirmar vínculo
Terceiro	Sistema exibe alerta antes de salvar

Diagrama: diagrams/agentig_rag/titularidade_justificativa.svg



Titularidade e Justificativa

Slide 9: Evolução 4 - Justificativa RAG

Título: Justificativa enriquecida com base de conhecimento

Versão anterior: justificativas estáticas e genéricas.


Versão atual: após a classificação, o sistema consulta a base por categoria, recupera os top-3 trechos e gera uma justificativa curta com Mistral.

Dados usados no prompt:

- categoria tributária;
- tipo do documento;
- emitente;
- beneficiário;
- valor;
- situação no IRPF;
- trechos recuperados da base.

Impacto: o usuário entende por que o documento recebeu aquela categoria e quais cuidados precisa verificar.

Diagrama completo do pipeline: diagrams/agentik_rag/pipeline_rag.svg



Pipeline RAG

Slide 10: Evolução 5 - Frontend

Título: Interface React mais completa

Páginas funcionais:

- **Chat RAG:** sugestões, fontes consultadas, quantidade de chunks e score médio.
- **Upload Fiscal:** drag-and-drop, extração, classificação, titularidade e salvamento revisado.
- **Base de Conhecimento:** adicionar, remover e re-indexar documentos.
- **Histórico:** filtros, exclusão, agrupamento por categoria e resumo anual.
- **Avaliação:** métricas de recuperação, avaliação completa e comparação de modelos.
- **Status:** Ollama, modelos, chunks e estado do pipeline.

Mensagem visual: mostrar a interface como hub do sistema. Usar cartões ou uma grade de páginas com ícones.

Slide 11: Base de Conhecimento

Título: Documentos próprios e relevantes ao domínio

Arquivo	Tipo	Relevância
guia_imposto_renda.txt	TXT	Regras resumidas de obrigatoriedade, deduções e documentos
pr-irpf-2024.pdf	PDF	Perguntas e respostas oficiais da Receita Federal

Explique que os documentos foram escolhidos por cobrirem dúvidas recorrentes sobre despesas médicas, educação, previdência privada, rendimentos, dependentes, aluguéis, prazos, penalidades e documentos fiscais.

Pipeline de ingestão:

Carregamento -> limpeza textual -> chunking 600/80 -> embeddings
MiniLM -> ChromaDB

A base pode ser ampliada pela interface, e a re-indexação aceita diferentes configurações para experimentos.

Por que chunk_size=600 e overlap=80?

Foram desenhadas e testadas 7 configurações via scripts/avaliar_chunking.py, avaliadas no dataset de perguntas do domínio IRPF:


Configuração	chunk_size	overlap	Observação
fixo_200_0	200	0	Trechos curtos, perda de contexto fiscal
fixo_400_40	400	40	Equilíbrio fraco, sobreposição insuficiente
fixo_600_80	600	80	Melhor equilíbrio contexto x precisão
fixo_800_120	800	120	Contexto rico, mas maior ruído semântico
fixo_1000_200	1000	200	Trechos longos demais para o modelo de embedding
sentenca	variável	0	Fragmentos irregulares em documentos fiscais
semantico	variável	variável	Experimental, sem vantagem clara no

Configuração	chunk_size	overlap	Observação
			domínio

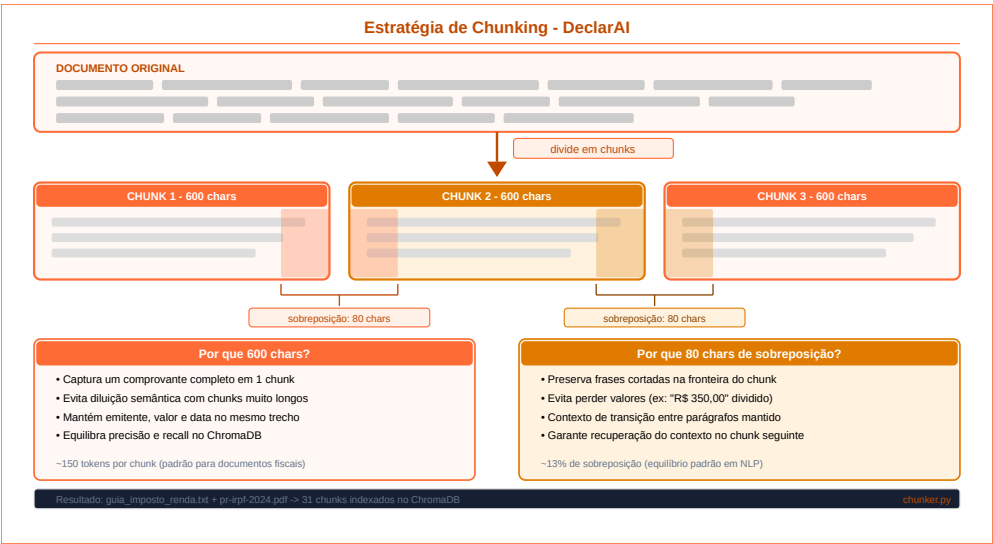
A configuração 600/80 foi selecionada por preservar regras fiscais completas (parágrafos com limites e exceções) sem gerar trechos longos demais que diluem a similaridade semântica.

Diagramas disponíveis:

- Ingestão e pré-processamento: `diagrams/agentig_rag/indexacao_e_ingestao.svg`
- Estratégia de chunking: `diagrams/chunking_estrategia.svg`



Ingestão e Pré-processamento



Estratégia de Chunking

Slide 12: Avaliação Quantitativa

Título: Como a qualidade foi medida

Dataset: `data/eval/perguntas.json`

- 60 perguntas anotadas.
- 12 categorias fiscais.


- 3 níveis de dificuldade.
- Cada pergunta possui resposta de referência e palavras-chave esperadas.

Métricas:

Métrica	Objetivo
Taxa de recuperação	medir perguntas com ao menos um chunk recuperado
Score médio de contexto	medir similaridade dos chunks retornados
Cobertura de keywords	medir termos esperados na resposta
Latência por pergunta	medir tempo total do pipeline

Também existe avaliação completa pela interface, usando `POST /evaluation/completa`, que executa recuperação e geração via LLM local. A avaliação de recuperação usa `POST /evaluation/recuperacao` e não exige Ollama.

Diagrama: `diagrams/agentick_rag/avaliacao_rag.svg`



Avaliação do Pipeline RAG

Slide 13: Resultados de Modelos

Título: Mistral + RAG teve melhor cobertura

Modelo	Cobertura	Latência média	Observação
Mistral + RAG	72,4%	8,2 s	Melhor cobertura
Phi4-mini + RAG	68,3%	7,0 s	Bom custo-benefício
Llama 3.2 3B + RAG	65,8%	6,4 s	Mais rápido
Gemma 3 4B + RAG	61,2%	6,9 s	Menor cobertura
Mistral sem RAG	44,1%	5,1 s	Linha de base

Conclusão: o RAG acrescenta +28,3 pontos percentuais ao Mistral em comparação com o LLM sem recuperação.

Slide 14: Ablation Study

Título: Por que o RAG faz diferença

Explique que o domínio fiscal depende de regras específicas, limites anuais, exceções e documentos oficiais. O LLM sem contexto tende a responder de forma genérica, enquanto o RAG injeta trechos recuperados da base própria.

Pontos-chave:

- limites fiscais mudam por exercício;
- regras de dedutibilidade têm exceções;
- a base oficial reduz alucinações;
- fontes e scores tornam a resposta auditável.

Slide 15: Conformidade com a Atividade

Título: Requisitos técnicos atendidos

Critério	Status
Problema e domínio	IRPF, público-alvo e relevância definidos
Base própria	TXT fiscal e PDF oficial da Receita Federal
Ingestão e pré-processamento	loader, limpeza, metadados e chunking
Embeddings e recuperação	MiniLM, ChromaDB e CrossEncoder
Agentic RAG	ferramentas acionadas por intenção
LLM aberto	Mistral via Ollama
Interface	React + FastAPI + Swagger
Avaliação	dataset, scripts e métricas
Documentação	README, relatório, diagramas e slides

Mensagem principal: o projeto cobre todos os requisitos técnicos obrigatórios e os critérios de documentação, avaliação e demonstração.

Slide 16: Limitações e Próximos Passos

Título: Limitações conhecidas

- Depende do Ollama instalado e do modelo baixado.
- Regras fiscais exigem atualização anual da base.
- OCR pode falhar em imagens ruins.
- A classificação ainda exige revisão humana.
- O sistema apoia o contribuinte, mas não substitui contador.

Próximos passos:

- busca híbrida BM25 + vetorial;
- comparação de embeddings;
- chunking semântico;

- base atualizada para o exercício fiscal vigente;
- dataset anotado de documentos enviados.

Slide 17: Demonstração ao Vivo

Título: Roteiro da apresentação

1. Abrir o frontend em `http://localhost:3000`.
2. Mostrar status do sistema e disponibilidade do Ollama.
3. No chat, perguntar: “Curso de inglês é dedutível como educação?”
4. Mostrar fontes consultadas, score e resposta restritiva.
5. Enviar recibo médico de exemplo na tela de upload.
6. Mostrar extração, classificação, titularidade e justificativa.
7. Salvar o documento após revisão.
8. Abrir histórico e mostrar resumo anual.
9. Executar avaliação de recuperação ao vivo e mostrar a opção de avaliação completa.
10. Abrir Swagger em `http://localhost:8000/docs`.

Slide 18: Agradecimentos

Título: Agradecimentos

Mensagem principal: agradecer à banca e abrir espaço para perguntas.

Texto sugerido:

Obrigado pela atenção.

O DeclarAI evoluiu de um RAG básico para um Micro SaaS acadêmico com comportamento agêntico, avaliação quantitativa, interface utilizável, privacidade local e documentação completa.

Visual sugerido: tela limpa com logo do DeclarAI, nomes da equipe, UEA, disciplina e uma chamada curta: Perguntas?.

Checklist Final para o NotebookLM

Antes de finalizar a apresentação, verificar:

- todos os slides têm título padronizado;
- todos os slides estão em português brasileiro;
- a capa usa composição nova e não a capa antiga;
- o rodapé aparece de forma discreta e consistente;
- os diagramas estão legíveis e sem sobreposição;
- as cores seguem a paleta definida;
- as métricas são exatamente as informadas neste PDF;
- os endpoints e tecnologias não foram alterados;
- o sistema é descrito como apoio informativo, não como substituto de contador;
- a apresentação fecha com roteiro de demonstração ao vivo.

Regras Consolidadas para o NotebookLM

- Gerar exatamente 18 slides em formato 16:9.
- Usar português brasileiro com acentuação correta.
- Não citar nomes de ramificações do Git. Usar apenas versão anterior e versão atual.
- Usar rodapé com o nome do projeto: DeclarAI | UEA | Oficina e Desenvolvimento de Sistemas I | Junho de 2026.
- Usar títulos com 50px, textos principais com 27px e notas ou observações com 23px.
- Não usar travessão. Use hífen simples quando precisar separar ideias.
- Incluir o slide 2 chamado Estrutura de Apresentação.
- Encerrar com o slide 18 chamado Agradecimentos.
- Não inventar métricas, tecnologias, autores ou endpoints.
- Descrever o sistema como apoio informativo, nunca como substituto de contador.