



DeclarAI

Assistente Fiscal Inteligente

Agentic RAG para Apoio Inteligente a Declaracao do IRPF

Juliana Ballin Lima | Fernando Luiz Da Silva Freire

UEA - Oficina e Desenvolvimento de Sistemas I - Junho de 2026

Agenda

1. Problema e proposta de valor
2. Arquitetura geral e privacidade
3. Fluxo do orquestrador de intencao
4. **Por que e Agentic RAG?** novo
5. **LLM em cada etapa do fluxo** novo
6. Evolucoes implementadas (1 a 5)
7. Base de conhecimento e chunking
8. Resultados empiricos
9. **Comparativo de LLMs** ampliado
10. Conformidade, limitacoes e demo

Por que o DeclarAI e necessario?


Dificuldades do Contribuinte

- Identificar o que e ou nao dedutivel
- Evitar inclusao de despesas bloqueadas pela Receita Federal
- Separar documentos do titular, dependentes e terceiros
- Compreender regras fiscais complexas

Proposta de Valor DeclarAI

- Assistente local especializado no dominio fiscal brasileiro
- Respostas fundamentadas estritamente em documentos oficiais de referencia
- Processamento 100% local para garantir a privacidade de dados sensiveis (renda, saude, CPFs)

Arquitetura Geral



Por que rejeitar APIs de nuvem?

Razao

Impacto

LGPD

Impede vazamento de CPFs, dados de saúde e renda


Independência

Executa offline, sem dependência de internet

Custo

Elimina custo recorrente por token (inviável para SaaS)

Fluxo Geral - Orquestrador de Intencao



Por que e Agentic RAG?

RAG classico vs. Agentic RAG

	RAG classico	Agentic RAG
Fluxo	unico e fixo	escolhido por intencao
Ferramentas	1 pipeline	6 ferramentas
Classificacao regras	fixas	LLM com fallback

Caracteristicas agenticas presentes

- **Percepcao:** classifica a intencao de cada entrada do usuario
- **Decisao:** escolhe a ferramenta certa entre chat RAG, upload, historico e avaliacao
- **Acao:** executa pipeline especifico por tipo de entrada
- **Memoria:** registra no SQLite com justificativa normativa
- **Verificacao:** valida titularidade

LLM em cada etapa do fluxo

Etapa	Usa LLM?	Papel do Mistral
Intencao do usuario	Sim	Classifica rota: chat, upload, historico ou metricas
Chat RAG	Sim	Gera resposta com base nos chunks recuperados
Classificacao fiscal	Sim	Decide categoria com fallback por regras
Verificacao de titularidade	Nao	Regras deterministicas (comparacao de nome e CPF)
Justificativa RAG	Sim	Redige justificativa normativa com top-3 chunks

Evolucao 1 - Precisao semantica via Re-ranking



Versao anterior


Busca Vetorial Direta (MiniLM): retornava trechos baseados apenas em similaridade, falhando em capturar negacoes.

Versao atual (CrossEncoder)

ChromaDB recupera Top-15, o mmarco-multilingual reavalia pares (pergunta + trecho) e filtra para Top-5.

Ganhos:

Evolucao 2 - Classificacao LLM-first com fallback



Extração PDF, HTML, OCR - prompt estruturado.


Mistral 7B avalia o contexto em 8 categorias fiscais.

Decisao Acao

SIM origem = llm
(captura regionalismos e abreviaco es)

NAO busca robusta por palavras-chave

Evolucoes 3 e 4 - Titularidade e RAG Explicativo



Etapa 1 - Validacao de Vinculo

Compara beneficiario do recibo com o perfil do declarante.

Etapa 2 - Triagem de Risco

Titular (Aprovado), Dependente (Requer confirmacao) ou Terceiro (Alerta vermelho: nao dedutivel).

Etapa 3 - Justificativa (2o RAG)

Consulta top-3 chunks especificos da categoria para gerar explicacao normativa com Mistral.

Etapa 4 - Revisao

Evolucao 5 - O painel de controle do Contribuinte

Chat RAG

Sugestoes ativas,
visualizacao de fontes e
exibicao do score de
similaridade.

Upload Fiscal

Interface drag-and-drop,
extracao ao vivo e painel
de alerta de titularidade.

Historico

Agrupamento de
categorias, resumo

Base de Conhecimento

Adicao dinamica, remocao
e re-indexacao visual de
arquivos.

Metricas


Rota de teste local e
comparacao RAG
diretamente via frontend.

Monitor de Status

Indicadores em tempo real
do Ollama. modelos



Estrategia de ingestao e preservacao semantica



Chunk_size = 600 | Overlap = 80 | 384 dims (MiniLM)

ConfiguracaoResultado

200 / 0

Grave perda de contexto fiscal

600 / 80


Melhor equilibrio

1000 / 200

Ruido semantico excessivo

Documentos:

Resultados empiricos do Pipeline RAG



Avaliação local e offline, inspirada nas métricas de Context Precision e Answer Relevancy (sem

Selecao de LLM local - Comparativo completo

Cobertura de keywords no dominio fiscal

Modelo	Cobertura	Latencia
Mistral 7B + RAG	72,4%	8,2 s
Phi4-mini + RAG	68,3%	7,0 s
Llama 3.2 (3B) + RAG	65,8%	6,4 s
Gemma 3 (4B) + RAG	61,2%	6,9 s

Ablation Study

A arquitetura vetorial adiciona **+28,3 pontos percentuais** de precisao, blindando o sistema contra limites fiscais de anos anteriores presentes no peso do LLM basico.

Por que o Mistral foi selecionado?

- Maior cobertura no dominio fiscal PT-RR

Conformidade integral com os requisitos da disciplina

Criterio	Implementacao
Problema delimitado	IRPF, publico-alvo leigo e necessidade de privacidade definidos
Base propria	Ingestao do TXT guia e PDF oficial de P&R da Receita Federal
Pipeline vetorial	Chunking 600/80, ChromaDB e embeddings MiniLM
Agentic RAG	Orquestracao de ferramentas por intencao + CrossEncoder re-ranking
Execucao local	LLM Mistral via Ollama, zero chamadas externas de API

Limitacoes arquitetonicas e horizontes futuros

Limitacoes conhecidas

- Dependencia de hardware com capacidade para Ollama/Mistral
- Qualidade de extracao sujeita a falhas de OCR em comprovantes amassados ou fotos ruins
- Exigencia de atualizacao anual manual da base oficial (regras mudam por exercicio)

Proximos passos tecnicos

- Implementacao de busca hibrida (BM25 + vetorial) para lidar com exatidao de numeracao de leis
- Migracao de chunking fixo para chunking semantico baseado em fronteiras de paragrafos legais
- Construcão de dataset massivo de documentos anotados para fine-tuning local do classificador

O DeclarAI e um apoio informativo e nao substitui um contador profissional.

Demonstracao pratica

1. **Verificacao** de status do backend (Ollama + Base)
2. **Chat RAG:** consulta sobre dedutibilidade de curso de idiomas
3. **Upload Fiscal:** extracao, classificacao e bloqueio de despesa de terceiro
4. **Auditoria:** revisao do Historico SQLite e justificativas normativas geradas
5. **Avaliacao:** execucao de metricas locais ao vivo via painel

Perguntas?

DeclarAI

Juliana Ballin Lima
Fernando Luiz Da Silva Freire

UEA - Junho de 2026